数理科学与工程学院

程序设计说明书

2026 / 2027 学年第一学期

实现简化的 YOLOv1 进行手写数字检测

项目	信息
姓名	吉阳
学号	250980418
专业	光电信息科学与工程
学院	数理科学与工程学院
日期	2026 年 10 月 19 日

实验摘要

补全教师模板的卷积网络、IoU 匹配、多任务损失与 NMS，使用 MNIST 合成 64×64 数字检测图。最终训练 40 轮，在独立的 1500 张测试图、3771 个标注目标上，得到 Precision=86.32%、Recall=88.84%、F1=87.56%。正确检测要求类别一致且 IoU≥0.5；全部结果来自实际运行记录。

提交内容：完整源代码、训练权重、损失曲线、检测图、关键测试及本报告。

一、数据集构建与标签理解

采用教师提供的 create_dataset.py，以黑色 64×64 灰度画布合成每张 0~5 个数字。按教师原代码将 28×28 MNIST 图缩放到 8~14 像素，再随机粘贴，重叠区域取像素最大值。这里的缩放因子 0.3~0.5 乘的是原始 28 像素，而非画布的 64 像素。

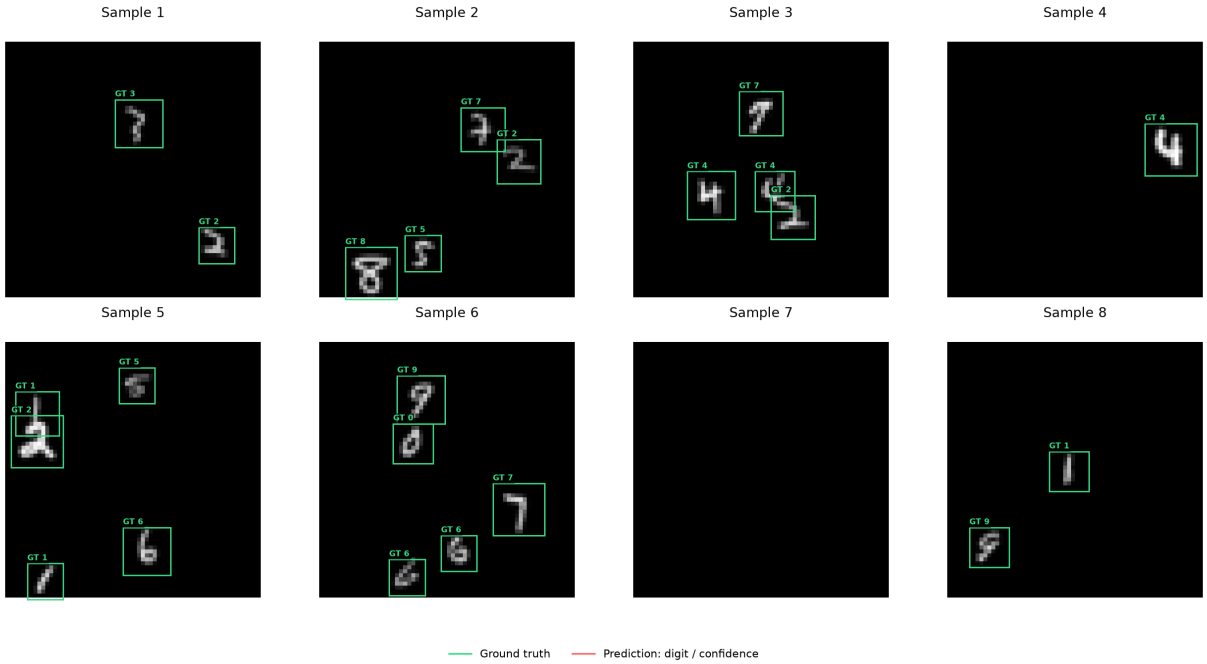


图 1 合成训练样本；绿色框与数字为真实标注。

标签张量是什么形状？

单张为 (S,S,5B+C)=(7,7,20)，批次为 (N,7,7,20)。前两维是网格行、列；前 10 个数是两个 (cx,cy,w,h,conf) 框槽，后 10 个数是 0~9 的 one-hot 类别。cx、cy、w、h 均为整幅图的归一化坐标。

为什么由中心所在网格负责？同格两个目标怎么办？

中心点提供明确的目标归属规则，避免多个网格同时监督同一目标。YOLOv1 每格只有一组类别分布，即使 B=2，也无法独立表达同格两个不同类别目标。原代码会覆盖框坐标并累积类别位，本实现于粘贴前跳过同格冲突，避免图中有数字而标签不一致；此举限制了任务的拥挤程度。

标签里的 conf 如何设置？

空网格的框槽 conf=0；有目标网格按教师实际代码重复保存真值，两个槽的 conf 均为 1。这只是重复存储，损失函数仍按 IoU 只选择一个预测框作为正样本，其余框监督为 0。原文件注释和实际赋值不一致，报告以实际赋值为准。

数据划分：MNIST 训练集前 50000 张供训练合成，后 10000 张供验证合成；MNIST 官方测试集仅供最终测试。验证 seed=123，测试 seed=321，训练组合逐轮更换。

二、简化 YOLOv1 网络结构

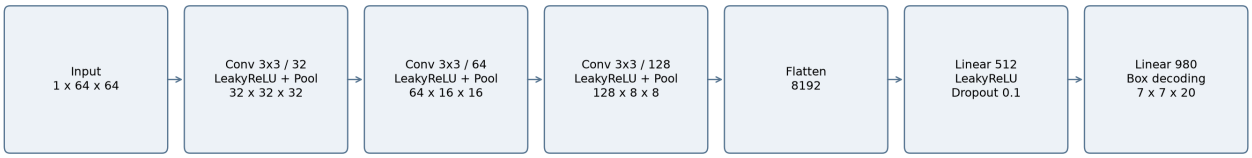


图 2 网络结构；张量维度按通道×高×宽表示。

阶段	操作	输出（不含 batch）
输入	64×64 灰度图，像素归一化至 [0,1]	1×64×64
卷积块 1	Conv(1,32,3,pad=1) + LeakyReLU(0.1) + MaxPool(2)	32×32×32
卷积块 2	Conv(32,64,3,pad=1) + LeakyReLU + MaxPool(2)	64×16×16
卷积块 3	Conv(64,128,3,pad=1) + LeakyReLU + MaxPool(2)	128×8×8
展平	flatten(start_dim=1)	8192
全连接头	Linear(8192,512) + LeakyReLU + Dropout(0.1)	512
输出	Linear(512,980) + reshape + 框解码	7×7×20

输出维度与激活设计

输出总维度为 7×7×(5×2+10)=980，模型共有 4,790,228 个可训练参数。forward 依次完成 backbone、flatten、head、reshape；三个卷积块符合轻量模型要求。

为约束中心点落在负责网格中，头部先输出局部偏移 tx、ty，再计算 cx=(sigmoid(tx)+gx)/7、cy=(sigmoid(ty)+gy)/7。宽高 w、h 与 conf 使用 sigmoid。最终输出仍然是教师标签使用的全图坐标，因此 loss、NMS、可视化均不重复加网格偏移。

类别分量保留原始 logits，直接送入交叉熵；预测类别取 argmax。NMS 按题目要求使用框 conf 作为筛选和排序分数。训练置信度目标是目标存在性，本实现没有把它描述成定位 IoU 或经过校准的类别概率。

实现中的稳定性处理

用假输入自动算出 feat_dim，避免手算维度错误；初始框宽高约为画布的 0.17，初始 conf 约为 0.05，减少大量空网格造成的初始梯度冲击。训练进行梯度裁剪，全空白 batch 也能计算有限损失并正常反向传播。

三、IoU 匹配与多任务损失

1. IoU 与负责框的确定

先将 (cx,cy,w,h) 转为左右上下边界。交集宽高取两个框边界的交叠长度并截断为非负，IoU=交集面积/(面积1+面积2-交集面积)，零面积框返回 0。实现支持广播，可同时计算所有网格和两个预测框的 IoU。

对每个有目标网格，从标签中取一个有效真值框，计算其与 B 个预测框的 IoU，用 argmax 选择唯一负责框。该选择在 no_grad 中进行。若 IoU 相同，由 argmax 的确定性顺序选择第一个。负责框 mask 为 R，其补集为 noobj mask。

2. 损失公式（N 为 batch 图像数）

分量	实际采用的形式
坐标	$L_{coord} = 5/N \times \Sigma R \times [(cx-cx^*)^2 + (cy-cy^*)^2 + 2(w-w^*)^2 + 2(h-h^*)^2]$
置信度	$L_{conf} = 1/N \times [\Sigma R(conf-1)^2 + 0.5 \Sigma (1-R)conf^2]$
类别	$L_{cls} = 1/N \times \Sigma$(有目标网格) CrossEntropy(logits, class_id)
总损失	$L = L_{coord} + L_{conf} + L_{cls}$

坐标仅监督负责框；类别仅监督有目标网格；置信度同时监督负责框、同格未负责框和空网格框。三个分量均按图像数归一化，日志中的加权分量可直接相加得到总损失。这里按作业要求采用原始宽高 MSE 和 conf 目标 1，未使用原始论文的 sqrt(w,h) 损失或 IoU 置信度目标。

为什么负样本的置信度权重要较小？

每图有 7×7×2=98 个框，而有效目标平均只有约 2~3 个。负框远多于正框，若同权求和，模型容易通过把所有 conf 压低来降低损失。lambda_noobj=0.5 降低负样本支配程度，同时保留对误报的惩罚。

为什么 x、y 与 w、h 可以使用不同权重？

中心点决定目标位置，宽高决定目标尺度；相同的绝对误差对小框的相对尺度影响更大。本实验在全图归一化坐标下使用 xy_weight=1、wh_weight=2，适度加强小数字的尺度约束。权重应结合梯度、IoU 和验证结果选择，并非越大越好。

同格两个目标是否会由 B=2 自动解决？

不会。B 个框是对同一格目标的多个候选定位器，但只共享一组类别输出，本损失也只监督一个负责框。要处理同格多个目标，应改变标签表示和检测头，例如使用多尺度检测、更多独立类别预测或其他匹配机制。

四、训练过程与实验结果

最终设置：Adam，初始 lr=0.001，weight_decay=1e-5；余弦衰减至初始学习率的 5%；batch_size=64，epochs=40；每轮重新合成 16000 张训练图，验证集 1200 张。设备为 NVIDIA GeForce RTX 5060 Laptop GPU。训练循环耗时 481.8 秒（不含初始合成、最终评估及报告生成）。

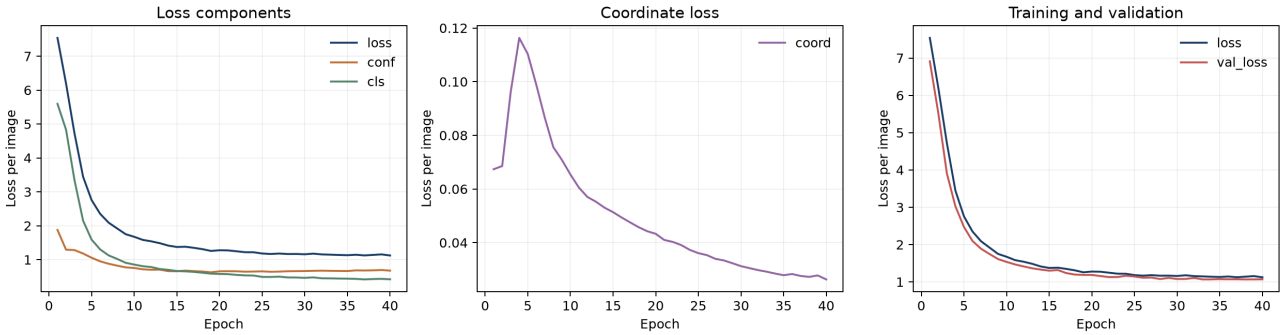


图 3 实测训练损失、坐标损失及验证损失；均为每张图的加权损失。

总训练损失从第 1 轮 7.5387 降到最后一轮 1.1227。按验证总损失选择第 38 轮权重，验证损失 1.0660。报告和演示默认加载这份最佳权重，而非自动采用最后一轮。

训练策略	Precision	Recall	F1
固定 12000 图 / 30 轮	44.80%	44.68%	44.74%
每轮更新 16000 图 / 40 轮	86.32%	88.84%	87.56%

固定小样本实验出现训练损失接近 0、验证损失偏高的过拟合。改进实验更换合成组合并增加样本数和轮数，提高了泛化能力。此处多项训练设置同时变化，结果只能证明整体方案有效，不能作为单变量消融实验。

评估协议与阈值

最终测试共 1500 图、3771 个目标，含 207 张空白图。conf 阈值 0.4 仅根据验证集 F1 在候选值 0.2/0.3/0.4/0.5/0.6 中选择；按类别 NMS 的 IoU 阈值为 0.5。同类别且 IoU≥0.5 才算 TP，每个真值最多匹配一次。

测试 TP=3350、FP=531、FN=421；Precision=86.32%，Recall=88.84%，F1=87.56%。正确匹配框平均 IoU=0.731。这些是检测指标，不是单数字分类准确率，也不是 mAP。

五、独立测试集可视化（至少三张）

以下取测试集中最先出现的三张非空图，保留实际误检和漏检。绿色为真值，红色为预测；红色文字给出数字类别和框置信度。完整 8 图总览另见 outputs/predictions.png。

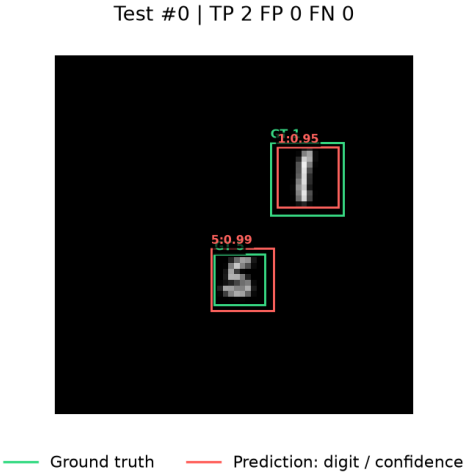


图 4 测试索引 #0
真实数字：1，5
预测数字（置信度）：5 (0.99)；1 (0.95)
TP=2，FP=0，FN=0。
类别错误会同时造成一次误检和一次漏检；定位低于 IoU 标准同样不计为正确检测。

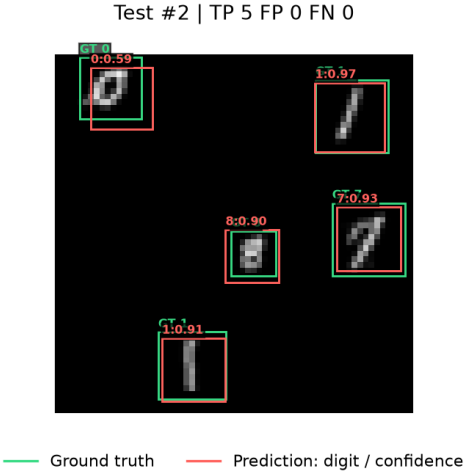


图 5 测试索引 #2
真实数字：0，1，8，7，1
预测数字（置信度）：1 (0.97)；7 (0.93)；1 (0.91)；8 (0.90)；0 (0.59)
TP=5，FP=0，FN=0。
类别错误会同时造成一次误检和一次漏检；定位低于 IoU 标准同样不计为正确检测。

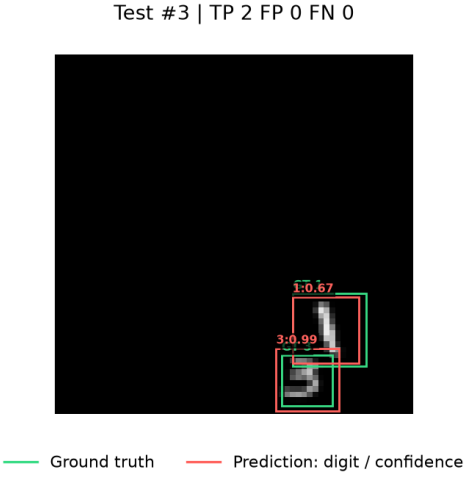
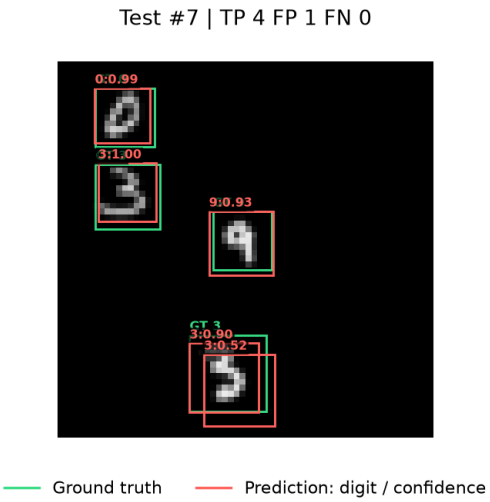


图 6 测试索引 #3
真实数字：1，3
预测数字（置信度）：3 (0.99)；1 (0.67)
TP=2，FP=0，FN=0。
类别错误会同时造成一次误检和一次漏检；定位低于 IoU 标准同样不计为正确检测。

六、失败案例、挑战与局限性

选择测试集中第一个含错误的非空样本 #7，TP=4、FP=1、FN=0，与原始预测 JSON 可以逐项核对。



该图有 4 个目标被正确匹配；下面重点分析未匹配项。额外的数字 3 候选置信度为 0.523，与最近真值 IoU=0.478，该真值已由另一个更高分框正确匹配，额外候选计为 FP。它与已保留同类框的 IoU=0.472，低于 NMS 阈值 0.5，因此仍被保留。图中目标跨过网格边界，相邻网格给出重复候选，是本例误检的直接表现。可在验证集比较更低的 NMS 阈值，同时检查是否误删相邻同类真目标。

遇到的挑战及解决方案

① 标签和坐标约定：统一为整图归一化坐标；修正教师注释与 conf 赋值不一致的说明。② 同格冲突：粘贴前检测占用并跳过冲突，保证类别 one-hot 与框对应。③ 训练过拟合：由固定图像改为逐轮重新合成，并用独立验证集选权重。④ 数值和空图：IoU 分母加保护，只在有目标网格计算交叉熵，负框正常参与置信度损失。

NMS 阈值怎样影响检测？

较低的 NMS IoU 阈值抑制更强，能减少重复框，但也可能删除相邻的同类数字；较高阈值保留更多重叠框，可能增加重复检测。本实现不跨类别抑制。置信度阈值是另一个参数：提高它通常减少候选框、降低误报，同时可能增加漏检。

局限与可改进方向

每格只能监督一个目标；合成器跳过冲突使评估比真实密集场景更容易。数字被压缩到 8~14 像素，细笔画丢失且仍可能相互遮挡；保留下采样细节、增加多尺度特征、更丰富的缩放或使用更大输入可能改善。全连接检测头对位置分布依赖较强，仍有误检和漏检；当前合成数据结果不能直接证明对真实拍摄手写图的泛化能力。

验证：12 项关键检查全部通过，覆盖 IoU、负责框选择、空图梯度、五框 NMS、类别隔离、一对一评估、输出维度、数据复现与冲突处理。复现命令与 5~8 分钟现场展示提纲见 README.md 和 展示讲稿.md。

参考：课程作业《大作业2026.docx》及教师六个 Python 模板；Redmon et al., You Only Look Once: Unified, Real-Time Object Detection, CVPR 2016；PyTorch / torchvision 文档（MNIST、CrossEntropyLoss）。